MINGGU 5

PENGOLAHAN DATA MENGGUNAKAN DATA MINING DENGAN ALGORITMA C4.5 & STUDI KASUS

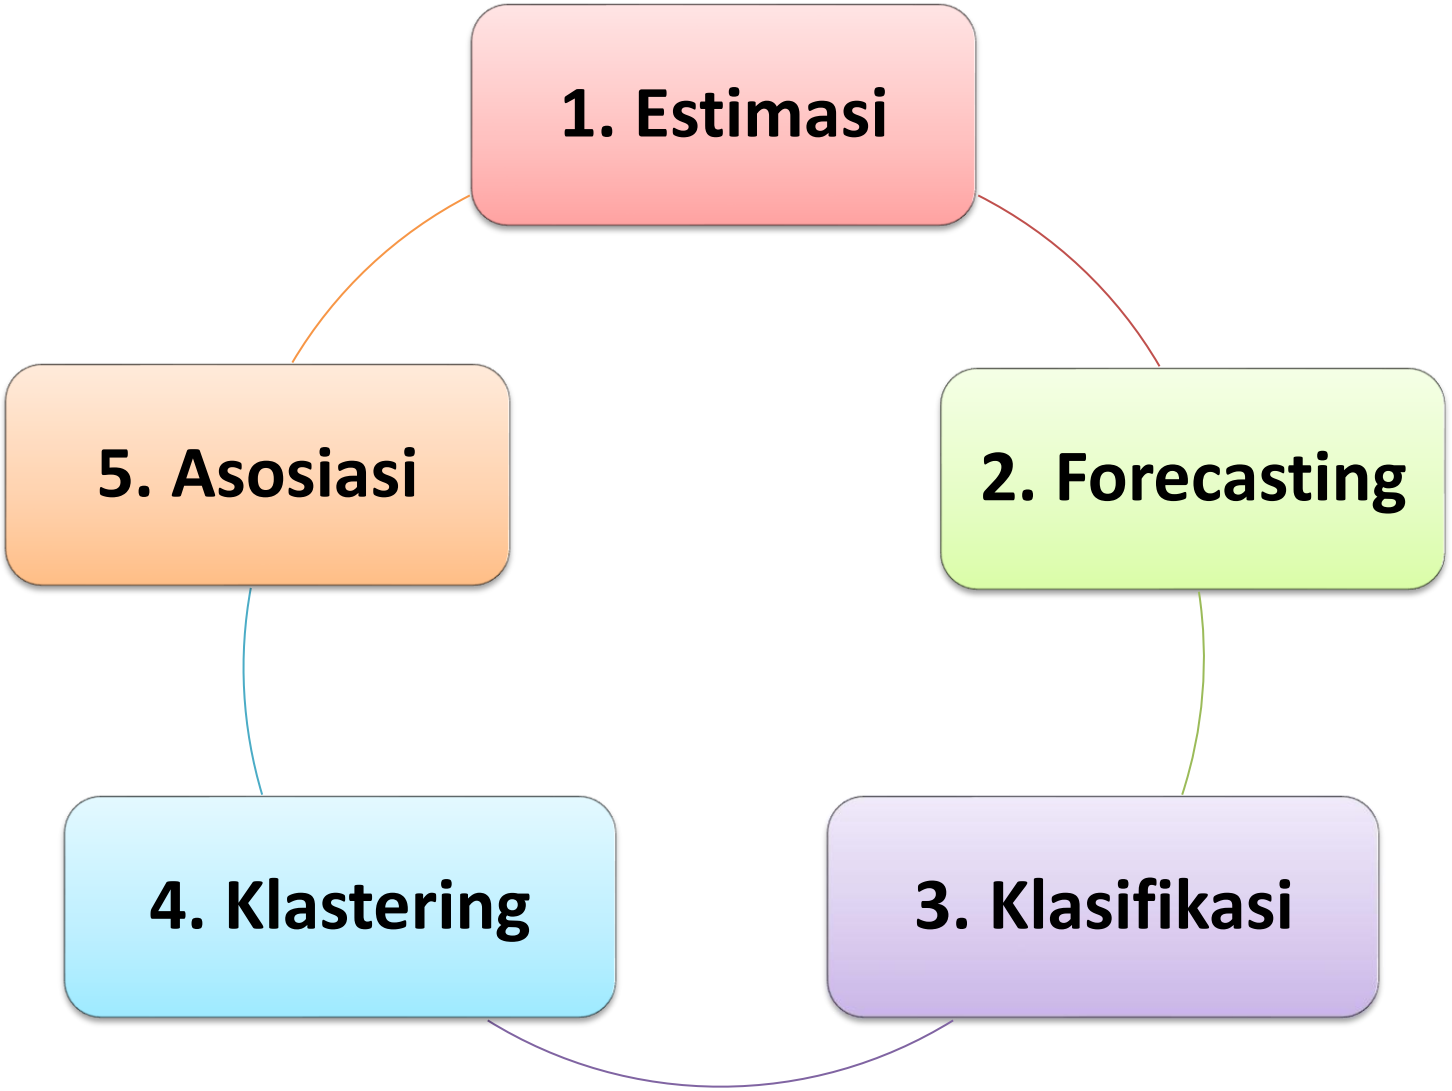
Copyright © September 2026

DATA MINING

Data mining umumnya terkait dengan penggalian data dalam kumpulan data dalam jumlah yang besar. Sebagian besar orang memperlakukan data mining sebagai istilah lain yang populer disebut Knowledge Data Discovery (KDD). Data mining melibatkan integrasi teknik dari berbagai disiplin ilmu seperti database dan teknologi data warehouse, statistik, metode pembelajaran mesin, komputasi kinerja tinggi, pengenalan pola, jaringan saraf, visualisasi data, pencarian informasi, gambar dan pemrosesan sinyal, dan data spasial atau temporal yang di analisis (Han dan Kamber, 2006).

Copyright © September 2026

Peran Utama Data Mining



 Copyright © September 2026

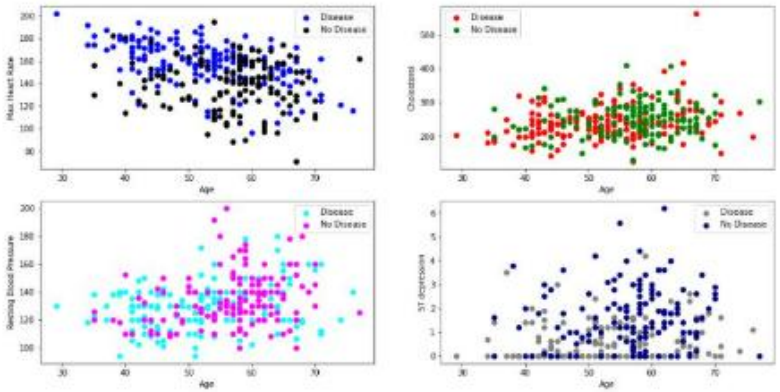
Metode Data Mining

1. Estimation (Estimasi):
   - Linear Regression, Neural Network, Support Vector Machine, etc
2. Prediction/Forecasting (Prediksi/Peramalan):
   - Linear Regression, Neural Network, Support Vector Machine, etc
3. Classification (Klasifikasi):
   - Naive Bayes, K-Nearest Neighbor, Algoritma C4.5, ID3, CART, Linear Discriminant Analysis, Logistic Regression, etc
4. Clustering (Klastering):
   - K-Means, K-Medoids, Self-Organizing Map (SOM), Fuzzy C-Means, etc
5. Association (Asosiasi):
   - FP-Growth, A Priori, Coefficient of Correlation, Chi Square, etc

 Copyright © September 2026

Contoh Jurnal Data Mining

1. **Estimation (Estimasi):**
   - Pendekatan ANN (Artificial Neural Network) Untuk Penentuan Prosentase Bobot Pekerjaan dan Estimasi Nilai Pekerjaan Struktur Pada Rumah Sakit
2. **Prediction/Forecasting (Prediksi/Peramalan):**
   - Aplikasi Artificial Neural Network (ANN) untuk Menentukan penyakit jantung



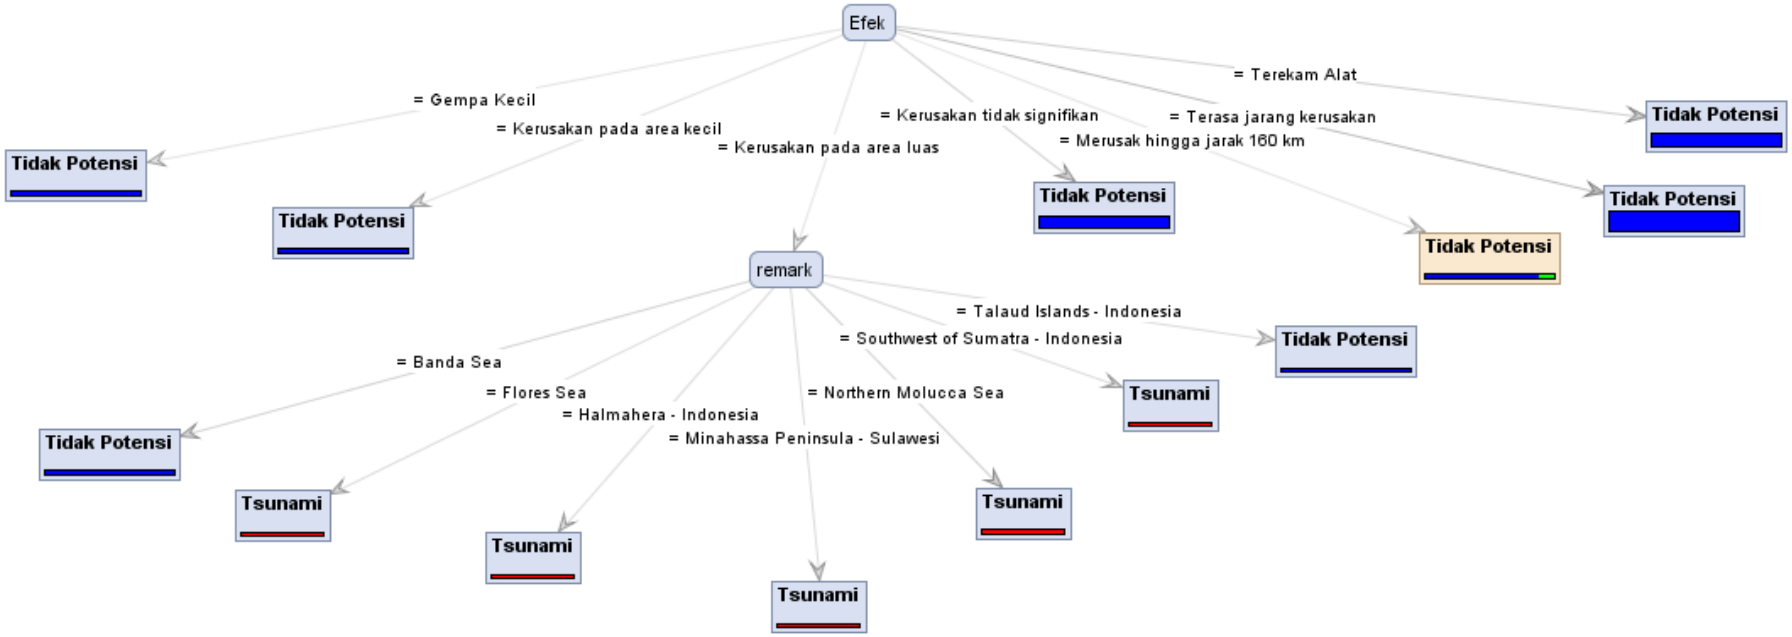
Contoh Prediksi untuk menentukan penyakit jantung menggunakn ANN

 Copyright © September 2026

Contoh Jurnal Data Mining

3. Classification (Klasifikasi):

- Klasifikasi Potensi Tsunami Berdasarkan Gempa Bumi Di Indonesia Menggunakan Algoritma C4.5



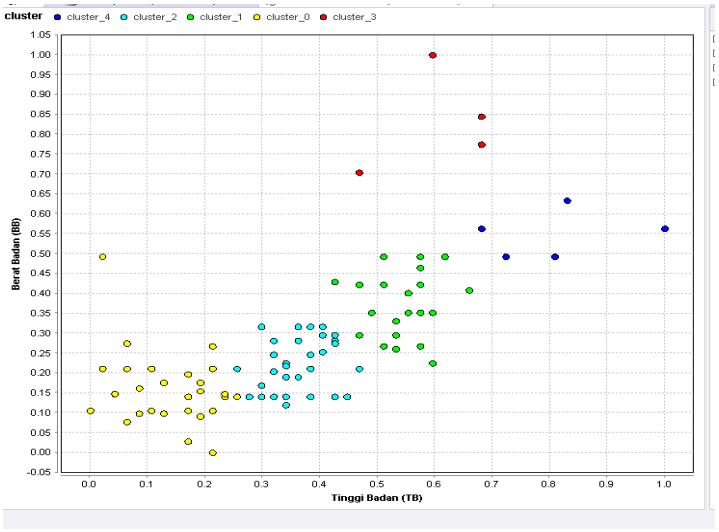
Contoh Pohon keputusan (*Decision Tree*) klasifikasi potensi tsunami dengan Algoritma C4.5

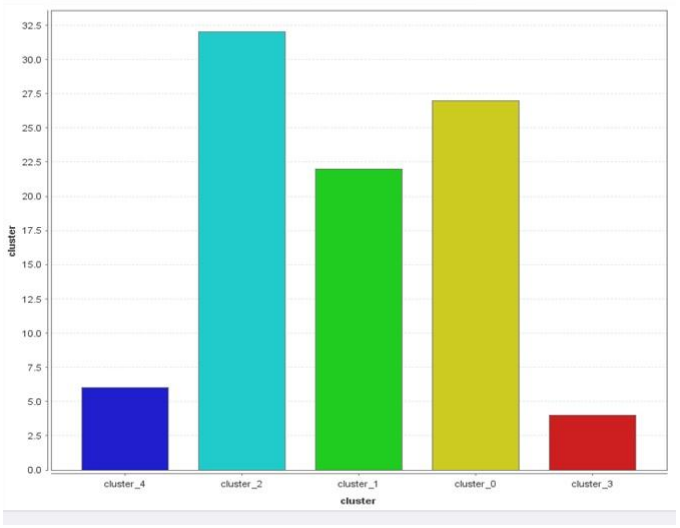
 Copyright © September 2026

Contoh Jurnal Data Mining

4. Clustering (Klastering):

- Algoritma K-Means Clustering untuk Menentukan Nilai Gizi Balita (Obesitas, Gizi Lebih, Gizi Baik, Gizi Kurang, Gizi Buruk)





Contoh Clustering/Pengelompokan nilai gizi balita & Hasil grafiknya menggunakan K-Means

 Copyright © September 2026

Contoh Jurnal Data Mining

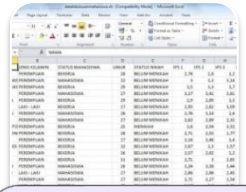
5. **Association (Asosiasi):**
   - Penerapan Data Mining Dengan metode Algoritma Apriori Untuk menentukan Pola Pembelian Ikan
   - Data Mining Penjualan Produk Dengan Metode Apriori Pada Indomaret Galang Kota
   - Implementasi Algoritma Apriori untuk Rekomendasi Produk pada Toko Olahraga

Itemsets	Support	Confidence
Shoes, Clothes	40,7%	91,7%
Pants, Jackets	31,5%	59%
Jackets, Clothes	38,9%	62%
Clothes, Jackets	38,9%	62%

Contoh penentuan rekomendasi penjualan barang menggunakan Apriori

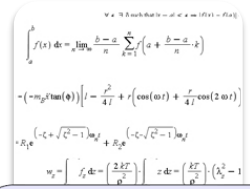
Copyright © September 2026

Proses Data Mining



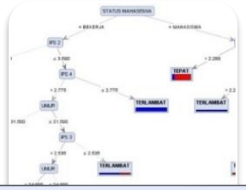
1. Himpunan Data

(Pemahaman dan Pengolahan Data)



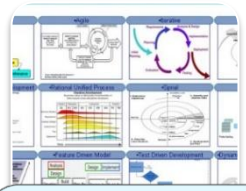
2. Metode Data Mining

(Pilih Metode Sesuai Karakter Data)



3. Pengetahuan

(Pola/Model/Rumus/ Tree/Rule/Cluster)



4. Evaluation

(Akurasi, AUC, RMSE, Lift Ratio,…)

DATA PRE-PROCESSING
Data Cleaning
Data Integration
Data Reduction
Data Transformation

Estimation
Prediction
Classification
Clustering
Association

Copyright © September 2026

1. Menentukan Himpunan Data (Dataset)

- Jenis dataset ada dua: **Private** dan **Public**
- **Private Dataset**: data set dapat diambil dari organisasi yang kita jadikan obyek penelitian
  - Bank, Rumah Sakit, Industri, Pabrik, Perusahaan Jasa, dll
- **Public Dataset**: data set dapat diambil dari repositori publik yang disepakati oleh para peneliti data mining
  - Kaggle (*https://www.kaggle.com/*)
  - BPS (https://www.bps.go.id/)
  - UCI Repository (https://archive.ics.uci.edu/ml/datasets.php)

Copyright © September 2026

2. Menentukan Metode Data Mining

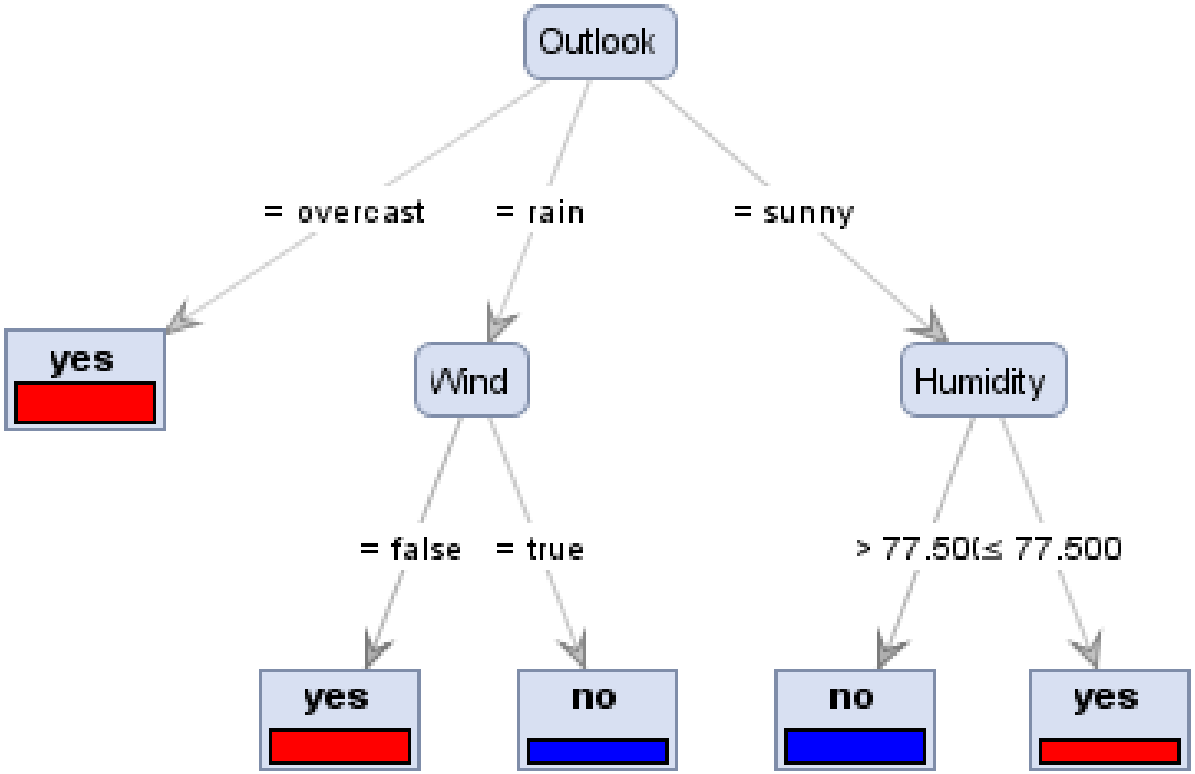
Metode Data Mining yang digunakan pada contoh kasus adalah Algoritma C4.5

Algoritma C4.5 merupakan algoritma yang umum digunakan untuk **mengklasifikasi** data.

Copyright © September 2026

3. Pengetahuan (Pola/Model)

Algoritma C4.5 akan menghasilkan pengetahuan berupa pola berbentuk Decision Tree (Pohon Keputusan)



 Copyright © September 2026

4. Evaluation (Akurasi, Error)

Akurasi merupakan ukuran dari seberapa baik model mengkorelasikan antara hasil dengan atribut dalam data yang telah disediakan. Terdapat berbagai model akurasi, tetapi semua model akurasi tergantung data yang digunakan.

Hasil pengolahan data menggunakan Algoritma C4.5 akan diukur Validasi dan Evaluasi untuk menentukan tingkat akurasi / mengukur performance akurasi dapat menggunakan model **Confusion Matrix**

Copyright © September 2026

Pengujian Model Data Mining

- Pembagian dataset:
  - Dua bagian: data training dan data testing
  - Tiga bagian: data training, data validation dan data testing
- **Data training** untuk pembentukan model, dan **data testing** digunakan untuk pengujian model

- Pemisahan data training dan testing
  1. Data dipisahkan secara manual
  2. Data dipisahkan otomatis dengan operator Split Data
  3. Data dipisahkan otomatis dengan X Validation (cross validation)

Catatan: Untuk mempermudah pengujian dapat menggunakan cross validation

Copyright © September 2026

STUDI KASUS

MENENTUKAN DATASET

https://ejournal.iocscience.org/index.php/mantik/article/view/3342

www.bsi.ac.id Universitas Bina Sarana Informatika Copyright © September 2026

1. Menentukan Data Set

Attribute

Class/Label/Target

	Sepal Length (cm)	Sepal Width (cm)	Petal Length (cm)	Petal Width (cm)	Type
1	5.1	3.5	1.4	0.2	*Iris setosa*
2	4.9	3.0	1.4	0.2	*Iris setosa*
3	4.7	3.2	1.3	0.2	*Iris setosa*
4	4.6	3.1	1.5	0.2	*Iris setosa*
5	5.0	3.6	1.4	0.2	*Iris setosa*
...					
51	7.0	3.2	4.7	1.4	*Iris versicolor*
52	6.4	3.2	4.5	1.5	*Iris versicolor*
53	6.9	3.1	4.9	1.5	*Iris versicolor*
54	5.5	2.3	4.0	1.3	*Iris versicolor*
55	6.5	2.8	4.6	1.5	*Iris versicolor*
...					
101	6.3	3.3	6.0	2.5	*Iris virginica*
102	5.8	2.7	5.1	1.9	*Iris virginica*
103	7.1	3.0	5.9	2.1	*Iris virginica*

Nominal

Numerik

Copyright © September 2026

1. Menentukan Data Set

A. Mengambil Dataset dari sumber data

tgl	tahun	timestamp	latitude	longitude	depth	magnitude	remark
01/01/2018	2018	10:48:13 PM	0,01	122,55	158	2,4	Minahassa Peninsula - Sulawesi
01/01/2018	2018	10:28:09 PM	0,2	125,41	10	3,3	Southern Molucca Sea
01/01/2018	2018	6:32:23 PM	8,3	123,53	10	2,9	Flores Region - Indonesia
01/01/2018	2018	5:46:55 PM	1,01	132,52	10	3,3	Irian Jaya Region - Indonesia
01/01/2018	2018	5:38:34 PM	0,27	121,83	170	2,6	Minahassa Peninsula - Sulawesi
01/01/2018	2018	4:32:39 PM	8,49	121,3	181	4,5	Flores Region - Indonesia
01/01/2018	2018	4:25:36 PM	7,96	116,84	288	4,5	Bali Sea
01/01/2018	2018	4:16:03 PM	9,82	124,25	10	3,1	Timor Region
01/01/2018	2018	4:05:55 PM	7,66	119,28	19	3,5	Flores Sea
01/01/2018	2018	3:55:24 PM	9,48	118,11	22	3,1	Sumbawa Region - Indonesia
01/01/2018	2018	10:40:24 AM	6,9	106,83	10	3,3	Java - Indonesia
01/01/2018	2018	9:17:58 AM	3,51	119,1	22	2,5	Sulawesi - Indonesia
01/01/2018	2018	9:04:34 AM	0,28	125,35	10	4	Southern Molucca Sea
01/01/2018	2018	9:03:10 AM	0,72	131,12	17	2,5	Irian Jaya Region - Indonesia
01/01/2018	2018	7:48:02 AM	0,59	122,34	61	1,7	Minahassa Peninsula - Sulawesi
01/01/2018	2018	7:32:00 AM	0,23	122,94	12	2,7	Minahassa Peninsula - Sulawesi

Copyright © September 2026

1. Menentukan Data Set

B. Menambahkan Label/Target pada kolom akhir yaitu **Potensi**

tgl	tahun	timestamp	latitude	longitude	depth	magnitude	remark	potensi
01/01/2018	2018	10:48:13 PM	0,01	122,55	158	2,4	Minahassa Peninsula - Sulawesi	Tidak Potensi
01/01/2018	2018	10:28:09 PM	0,2	125,41	10	3,3	Southern Molucca Sea	Tidak Potensi
01/01/2018	2018	6:32:23 PM	8,3	123,53	10	2,9	Flores Region - Indonesia	Tidak Potensi
01/01/2018	2018	5:46:55 PM	1,01	132,52	10	3,3	Irian Jaya Region - Indonesia	Tidak Potensi
01/01/2018	2018	5:38:34 PM	0,27	121,83	170	2,6	Minahassa Peninsula - Sulawesi	Tidak Potensi
01/01/2018	2018	4:32:39 PM	8,49	121,3	181	4,5	Flores Region - Indonesia	Tidak Potensi
01/01/2018	2018	4:25:36 PM	7,96	116,84	288	4,5	Bali Sea	Tidak Potensi
01/01/2018	2018	4:16:03 PM	9,82	124,25	10	3,1	Timor Region	Tidak Potensi
01/01/2018	2018	4:05:55 PM	7,66	119,28	19	3,5	Flores Sea	Tidak Potensi
01/01/2018	2018	3:55:24 PM	9,48	118,11	22	3,1	Sumbawa Region - Indonesia	Tidak Potensi
01/01/2018	2018	10:40:24 AM	6,9	106,83	10	3,3	Java - Indonesia	Tidak Potensi
01/01/2018	2018	9:17:58 AM	3,51	119,1	22	2,5	Sulawesi - Indonesia	Tidak Potensi
01/01/2018	2018	9:04:34 AM	0,28	125,35	10	4	Southern Molucca Sea	Tidak Potensi
01/01/2018	2018	9:03:10 AM	0,72	131,12	17	2,5	Irian Jaya Region - Indonesia	Tidak Potensi
01/01/2018	2018	7:48:02 AM	0,59	122,34	61	1,7	Minahassa Peninsula - Sulawesi	Tidak Potensi
01/01/2018	2018	7:32:00 AM	0,23	122,94	12	2,7	Minahassa Peninsula - Sulawesi	Tidak Potensi

Copyright © September 2026

1. Menentukan Data Set

B. Menambahkan Label/Target pada kolom akhir yaitu **Potensi**

Label potensi didapat dari nilai magnitude (skala Richter dan kedalaman terjadinya gempa (Depth)

Magnitude	Depth	Potensi
Lebih dari 7 SL	lebih dari 30 km	Tsunami
6.5-7 SL	kurang dari 30km	Longsor bawah laut
kurang dari 6.5	kurang dari 10km	Tidak Potensi

https://geodesigeodinamik.ft.ugm.ac.id/2019/10/04/faktor-yang-dapat-menjadi-penyebab-tsunami/

 Copyright © September 2026

1. Menentukan Data Set

C. Menghapus atribut Tanggal, Tahun dan merubah atribut timestamp menjadi kategori waktu pagi, siang, sore, malam

Pukul	Waktu
05:00 - 10:00	Pagi
11:00 - 15:00	Siang
15:00 - 18:00	Sore
18:00 - 05:00	Malam

Copyright © September 2026

1. Menentukan Data Set

Dataset setelah dilakukan penghapusan atribut yang tidak diperlukan dan pembentukan kategorikal atribut waktu didapatkan Tabel dataset yang terdiri dari 6 atribut, yaitu: Waktu (Pagi, Siang, Sore, Malam), Latitude, Longitude, Depth, Magnitude, Remark. Target atau label yang akan dihasilkan antara lain potensi tsunami, longsor bawah laut, dan tidak potensi tsunami.

Atribut	Label/Target
Waktu (pagi, siang,sore,malam)	Potensi (Tsunami, Longsor bawah laut, Tidak Potensi)
Latitude	
Longitude	
Depth	
Magnitude	
Remark	

Copyright © September 2026

1. Menentukan Data Set

Hasil Akhir dataset dibawah ini selanjutkan akan diolah menggunakan tools Rapid Miner sehingga menghasilkan output berupa pohon keputusan (decision tree).

Waktu	Latitude	Longitude	Depth	Magnitude	Remark	Potensi
malam	0,33	123,73	112	5,1	Minahassa Peninsula - Sulawesi	Tidak Potensi
pagi	0,54	128,1	17	7,2	Halmahera - Indonesia	Tsunami
pagi	6,46	101,7	10	4,9	Southwest of Sumatra - Indonesia	Tidak Potensi
pagi	4,41	102,14	43	4,8	Southern Sumatra - Indonesia	Tidak Potensi
malam	3,42	128,45	10	6,6	Seram - Indonesia	Longsor B Laut
pagi	4,41	102,14	43	4,8	Southern Sumatra - Indonesia	Tidak Potensi
sore	8,49	121,3	181	4,5	Flores Region - Indonesia	Tidak Potensi
sore	2,34	126,75	56	6,6	Northern Molucca Sea	Longsor B Laut
malam	1,89	122,53	10	6,9	Sulawesi - Indonesia	Longsor B Laut
sore	7,96	116,84	288	4,5	Bali Sea	Tidak Potensi
malam	6,11	130,34	157	4,3	Banda Sea	Tidak Potensi

Copyright © September 2026

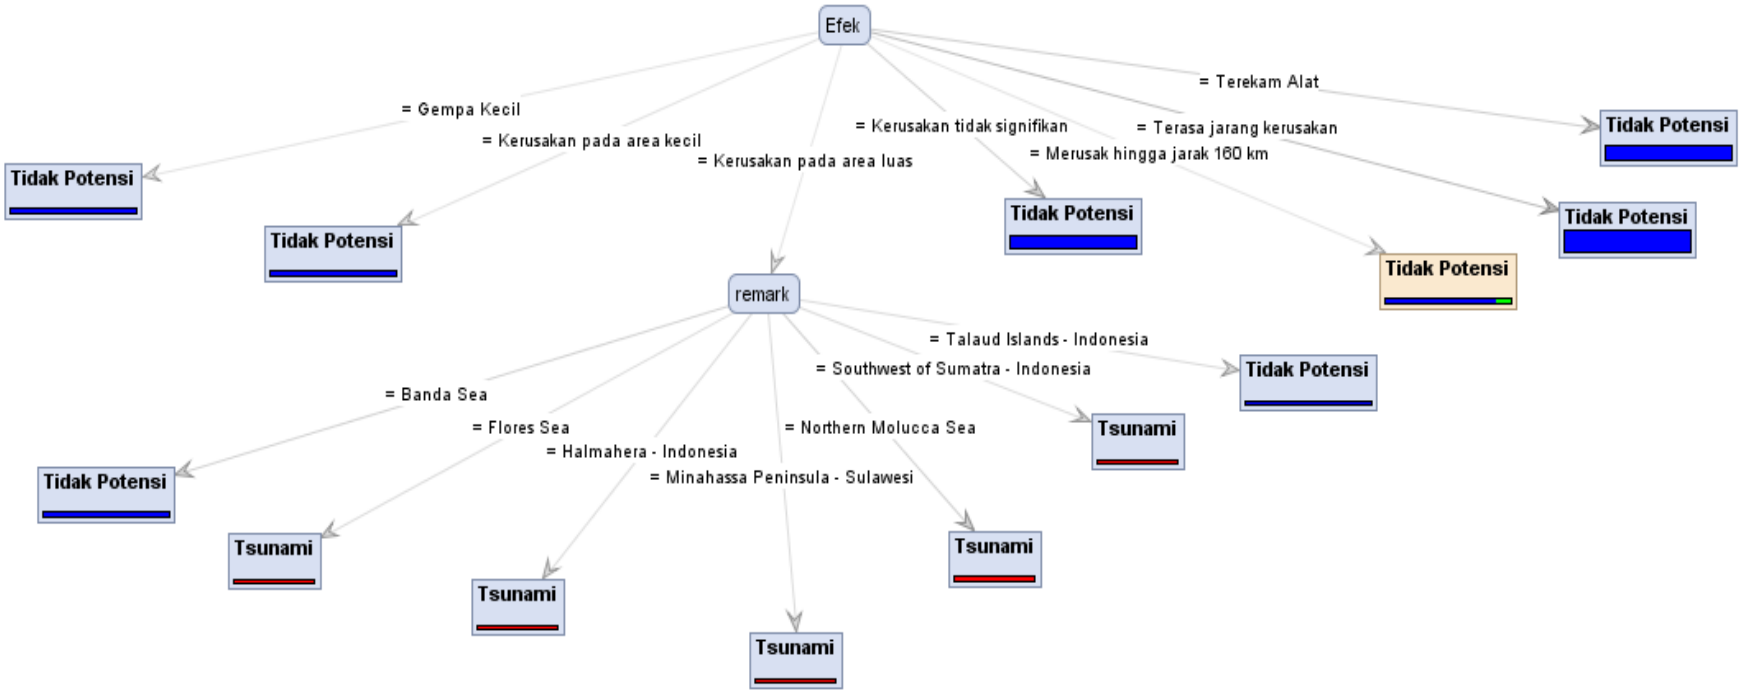
2. Menentukan Metode Data Mining

Metode Data Mining yang akan digunakan untuk memprediksi terjadinya potensi tsunami berdasarkan gempa bumi adalah metode Decision Tree menggunakan Algoritma C4.5

Copyright © September 2026

3. Pengetahuan (Pola/Model)

Hasil pengolahan data dengan menggunakan tool Rapidminer berupa pola berbentuk Decision Tree (Pohon Keputusan)



 Copyright © September 2026

4. Evaluation (Akurasi, Error)

Hasil pengujian akurasi dengan menggunakan metode 10-fold Cross Validation didapatkan nilai akurasi sebesar 99.96%

accuracy: 99.96% +/- 0.01% (mikro: 99.96%)

	true Tidak Potensi	true Longsor Bawah Laut	true Tsunami	class precision
pred. Tidak Potensi	50084	18	2	99.96%
pred. Longsor Bawah Laut	0	0	0	0.00%
pred. Tsunami	2	0	10	83.33%
class recall	100.00%	0.00%	83.33%	

Copyright © September 2026